

FACULTAD DE INGENIERIA Y CIENCIAS APLICADAS
MAESTRIA EN INTELIGENCIA ARTIFICIAL APLICADA
PROYECTO MIA - TTMZ0055-226

S10 - PROTOTIPO FINAL Y PRESENTACION

*Modelo predictivo del rendimiento deportivo en el futbol ecuatoriano (LigaPro Serie A)
a partir del presupuesto institucional y variables competitivas pre-temporada*

TUTOR: Medina Sotomayor Jaime Felipe
AUTOR 1: Castro Garcia Diego Fernando
AUTOR 2: Pila Caiza Cesar Silvio

Mayo 2026

Presentacion

Este documento corresponde al entregable S10 - Prototipo final y presentacion del proyecto de titulacion grupal de la Maestria en Inteligencia Artificial Aplicada. Su proposito es consolidar la version final del prototipo desarrollado, garantizar su funcionalidad, reproducibilidad, documentacion tecnica y coherencia metodologica, y fundamentar la presentacion oral (pitch) del proyecto.

El prototipo entregado es un sistema completo de inferencia que predice los puntos finales de cada club de la LigaPro Serie A a partir del presupuesto institucional y variables competitivas conocidas antes del inicio de la temporada. El sistema se ejecuta de manera 100% offline sobre el navegador (no requiere backend) gracias a la exportacion de los modelos a JSON y a la implementacion de la inferencia en JavaScript.

El presente informe se estructura en cinco secciones alineadas a la rubrica de evaluacion: (1) Prototipo final, (2) Reproducibilidad y evidencias, (3) Organizacion del repositorio, (4) Guion del pitch y (5) Reflexion final y uso de la retroalimentacion. Cada seccion referencia los artefactos del repositorio que la sustentan.

Indice

1. Prototipo final - implementacion y completitud
 - 1.1 Descripcion del problema y solucion
 - 1.2 Arquitectura del prototipo
 - 1.3 Modelo final entrenado y validado
 - 1.4 Mejoras incorporadas a lo largo del curso
 - 1.5 Evidencia de pruebas finales
2. Reproducibilidad y evidencias
 - 2.1 Requisitos tecnicos y dependencias
 - 2.2 Instrucciones de ejecucion paso a paso
 - 2.3 Pipeline general (datos -> modelo -> inferencia)
 - 2.4 Control de versiones
3. Organizacion estructurada del repositorio
 - 3.1 Mapa de carpetas
 - 3.2 Resultados finales y metricas comparativas
 - 3.3 Evidencias de robustez (referencia a anexos S9)
4. Pitch del proyecto (5-10 minutos)
 - 4.1 Contexto y problema abordado
 - 4.2 Enfoque metodologico
 - 4.3 Resultados y hallazgos
 - 4.4 Consideraciones eticas, riesgos y limitaciones
5. Reflexion final y uso de la retroalimentacion

1. Prototipo final - implementacion y completitud

1.1 Descripcion del problema y solucion

Los clubes de la LigaPro Serie A planifican cada temporada con presupuestos muy heterogeneos (rango 4 - 25 MUSD) y una alta incertidumbre sobre el rendimiento deportivo esperado. La directiva necesita una herramienta cuantitativa, reproducible y explicable que estime los puntos finales de la temporada antes del primer partido, para apoyar la negociacion con patrocinadores, la fijacion de objetivos deportivos y la rendicion de cuentas ante el directorio.

La solucion entregada es un modelo predictivo entrenado con datos reales de 16 clubes a lo largo de 8 temporadas (2019-2026, 128 filas) que combina variables presupuestarias (presupuesto, salarios, inversion en refuerzos) con variables competitivas pre-temporada (plantilla, cuerpo tecnico, contexto, rendimiento rezagado de la temporada anterior). El modelo se expone a traves de una interfaz web moderna que opera 100% offline en el navegador.

1.2 Arquitectura del prototipo

El prototipo se organiza en tres capas claramente desacopladas que permiten reentrenar, depurar y desplegar de manera independiente:

- **Capa de datos.** Fuentes canonicas en CSV organizadas por categoria (presupuestarias / competitivas) y dataset consolidado con variables rezagadas (ver scripts/consolidar_dataset.py).
- **Capa de modelado.** Tres pipelines comparados (Ridge, Random Forest, XGBoost) entrenados sobre la misma matriz de features pre-temporada y evaluados sobre splits temporales (train 2019-2023, val 2024, test 2025). El mejor por MAE en validacion se promueve a mejor_modelo.joblib (ver scripts/entrenamiento.py).
- **Capa de inferencia y UI.** Pagina web estatica (output/index.html) que carga los modelos exportados a JSON (ridge_model.json, rf_model.json, xgb_model.json) y ejecuta la prediccion en JavaScript. No requiere backend.

Tabla 1. Componentes del prototipo final

Componente	Archivo / carpeta	Funcion
Datos canonicos	data/categorias/	CSV por categoria
Dataset modelable	data/datasets/dataset_final.csv	128 filas x 24 cols
Consolidacion	scripts/consolidar_dataset.py	Une categorias + lags
Preprocesamiento	scripts/preprocesamiento.py	FEATURES, TARGET, splits
Entrenamiento	scripts/entrenamiento.py	3 modelos + seleccion
Exportacion	scripts/exportar_modelos_json.py	.joblib -> .json
Modelos	output/models/*.joblib + *.json	Artefactos entrenados
Card del modelo	output/models/model_card.json	Metricas + features
Interfaz web	output/index.html	UI offline (JS)

Inferencia CLI	scripts/predecir_equipo.py	Prediccion interactiva
Notebook EDA	notebooks/01_ligapro_COLAB.ipynb	Exploracion en Colab

Nota. Esta tabla resume los componentes que conforman el prototipo final. El archivo model_card.json actua como contrato de interfaz entre la capa de modelado y la capa de inferencia.

1.3 Modelo final entrenado y validado

El modelo final seleccionado por el script de entrenamiento, con base en el menor MAE en el conjunto de validacion (temporada 2024), es **RIDGE**. Esta eleccion se documenta en output/models/model_card.json y se materializa en el archivo mejor_modelo.joblib (copia del pipeline ganador).

El conjunto de variables predictoras se restringe deliberadamente a informacion conocida ANTES de que comience la temporada, lo que garantiza la validez del modelo como herramienta de planificacion pre-temporada y elimina cualquier riesgo de fuga temporal.

Tabla 2. Variables (features) usadas por el modelo

Bloque	Variable	Tipo
Recursos	presupuesto_musd	numerica
Recursos	salario_promedio_kusd	numerica
Recursos	inversion_refuerzos_musd	numerica
Plantilla	edad_promedio_plantilla	numerica
Plantilla	extranjeros_plantilla	entera
Cuerpo tecnico	antiguedad_dt_meses	entera
Contexto	participacion_internacional	entera (partidos)
Contexto	capacidad_estadio	entera
Inercia	posicion_temporada_anterior	ordinal
Lag deportivo	goles_favor_ant	entera
Lag deportivo	goles_contra_ant	entera
Lag deportivo	diferencia_goles_ant	entera
Lag deportivo	xg_ant	numerica
Lag deportivo	posesion_ant	% (0-100)
TARGET	puntos_temporada	numerica (0-90)

Nota. Los lags se construyen con shift de 1 periodo por equipo. Para 2019 se imputa la mediana del bloque, evitando NaN sin introducir informacion futura.

1.4 Mejoras incorporadas a lo largo del curso

El prototipo evoluciono semana a semana incorporando las retroalimentaciones recibidas. Las principales mejoras consolidadas en esta entrega final son:

- **S2-S3.** Reorganizacion del dataset por categoria (presupuestaria / competitiva) en data/categorias/, con un script de consolidacion que produce el dataset modelable. Mejora

la trazabilidad y mantenibilidad.

- **S4-S5.** Reformulacion del problema: se descarto la prediccion directa de posicion (ordinal con empates) y se adopto la prediccion de puntos_temporada, mas estable y con mejor poder predictivo.
- **S6-S7.** Comparacion sistematica de tres modelos con metricas robustas (MAE, RMSE, R2 y Spearman). Se identifico el sobreajuste de modelos no lineales con 80 filas y se justifico la eleccion de Ridge.
- **S8.** Construccion de la interfaz web moderna (output/index.html) con diseño responsive y selector de modelo, sustituyendo el primer prototipo de linea de comandos.
- **S9.** Anexos de validacion (docs/S9-ANEXOS DE VALIDACION.docx) con evidencia cuantitativa de validacion, robustez e interpretabilidad.
- **S10.** Eliminacion de la dependencia del backend FastAPI mediante la exportacion de los modelos a JSON y la reimplementacion de la inferencia en JavaScript. El prototipo se ejecuta 100% offline.

1.5 Evidencia de pruebas finales

Se realizaron las siguientes pruebas de aceptacion sobre la version final entregada:

Tabla 3. Pruebas finales realizadas sobre el prototipo

#	Prueba	Resultado
P1	Reentrenamiento end-to-end (consolidar -> entrenar)	OK
P2	Carga de modelos desde JSON en JavaScript	OK
P3	Apertura de output/index.html en navegador	OK
P4	Prediccion CLI con scripts/predecir_equipo.py	OK
P5	Consistencia val 2024 entre CLI y UI	OK (dif < 1e-2)
P6	Particion temporal sin fuga	OK
P7	Manejo de la primera temporada (2019)	OK

Nota. P1-P5 cubren el ciclo completo desde los CSV crudos hasta la respuesta visible al usuario. P6-P7 son pruebas de rectitud metodologica que blindan el modelo contra fugas y NaN.

2. Reproducibilidad y evidencias

2.1 Requisitos tecnicos y dependencias

El prototipo se ejecuta sobre Python 3.10 o superior y un navegador moderno (Chrome, Firefox, Edge). Las dependencias del backend de entrenamiento se declaran en output/requirements.txt:

```
fastapi
uvicorn
joblib
pandas
scikit-learn
xgboost
pydantic
```

Para la version offline en navegador (entrega final) no es necesario instalar dependencias: basta con abrir output/index.html. Las librerias FastAPI / Uvicorn solo se requieren si se desea levantar el backend opcional descrito en output/main.py.

2.2 Instrucciones de ejecucion paso a paso

Reproducir el prototipo desde cero requiere los siguientes pasos:

Tabla 4. Pasos para reproducir el prototipo


#	Comando / accion	Salida esperada
1	git clone <repo> && cd Modelo-Predictivo-Liga-Pro-Seria-A	Repositorio local.
2	python -m venv .venv && activate	Entorno virtual.
3	pip install -r output/requirements.txt	Dependencias listas.
4	python scripts/consolidar_dataset.py	dataset_final.csv (128 filas).
5	python scripts/entrenamiento.py	models/*.joblib + model_card.json.
6	python scripts/exportar_modelos_json.py	models/*_model.json.
7	Abrir output/index.html en el navegador	UI lista para inferencia.
8	Opcional: python -m http.server 5500 (en output/)	http://localhost:5500

Nota. Los pasos 4-6 son el pipeline reproducible de modelado; los pasos 7-8 corresponden al uso final del producto. La separacion permite reentrenar sin tocar la UI y viceversa.

2.3 Pipeline general

El pipeline completo del proyecto se ilustra a continuacion:

```
data/categorias/*.csv
|
v
scripts/consolidar_dataset.py --> data/datasets/dataset_final.csv
|
v
scripts/preprocesamiento.py --> FEATURES, TARGET, train/val/test
|
v
scripts/entrenamiento.py --> Ridge / RandomForest / XGBoost
|                          + seleccion del mejor por MAE val
```



Nota. Cada flecha del diagrama corresponde a un script o artefacto verificable en el repositorio. El pipeline es determinístico (random_state=42) y reproducible end-to-end en menos de 1 minuto.

2.4 Control de versiones

El proyecto se versiona con Git en el repositorio público github.com/parametrico005/modelo-predictivo-liga-pro-seria-a. La rama principal (main) contiene la versión estable; las ramas claudel/* contienen los avances iterativos. Cada commit incluye un mensaje descriptivo (feat / fix / docs / refactor) que permite trazar el origen de cada cambio.

Los artefactos binarios críticos (modelos .joblib y .json, dataset consolidado) se versionan en el mismo repositorio para garantizar que cualquier evaluador pueda reproducir la inferencia sin necesidad de reentrenar.

3. Organizacion estructurada del repositorio

3.1 Mapa de carpetas

```
Modelo-Predictivo-Liga-Pro-Seria-A/
|-- README.md                <- documentacion tecnica principal
|-- pasos.txt                <- guia rapida de ejecucion
|-- data/
|   |-- categorias/          <- FUENTE CANONICA (CSV)
|   |   |-- presupuestarias/
|   |   |-- competitivas/
|   |-- datasets/            <- INPUT DEL MODELO
|   |   |-- dataset_final.csv
|   |   |-- train.csv val.csv test.csv
|   |-- DATOS FINANZAS - LIGAPRO 2019-2026.xlsx
|-- scripts/
|   |-- consolidar_dataset.py
|   |-- preprocesamiento.py
|   |-- entrenamiento.py
|   |-- exportar_modelos_json.py
|   |-- prediccion.py
|   |-- predecir_equipo.py
|   |-- generar_s10_informe_final.py
|-- output/
|   |-- index.html            (UI moderna offline)
|   |-- main.py               (backend FastAPI opcional)
|   |-- requirements.txt
|   |-- models/
|   |   |-- ridge.joblib randomforest.joblib xgboost.joblib
|   |   |-- mejor_modelo.joblib (copia del mejor)
|   |   |-- ridge_model.json rf_model.json xgb_model.json
|   |   |-- model_card.json    (metricas + features + splits)
|-- notebooks/
|   |-- 01_ligapro_COLAB.ipynb (EDA y modelado)
|-- docs/
|   |-- Informe_Final_LigaPro.docx (S1-S8)
|   |-- S9-ANEXOS DE VALIDACION.docx (validacion)
|   |-- S10-INFORME-FINAL-Y-PRESENTACION.docx
|   |-- S10-INFORME-FINAL-Y-PRESENTACION.pdf (este documento)
```

3.2 Resultados finales y metricas comparativas

Los tres modelos se entrenan con los mismos features sobre el split train (2019-2023, 80 filas) y se evaluan en val (2024, 16 filas) y test (2025, 16 filas). El mejor por MAE en validacion es Ridge.

Tabla 5. Metricas comparativas en validacion (temporada 2024)

Modelo	MAE	RMSE	R2	Spearman
Ridge (mejor)	6.6512	7.828	0.6264	0.7237
Random Forest	9.2815	10.9369	0.2708	0.4657
XGBoost	11.388	13.25	-0.0703	0.2741

Nota. Ridge gana en validacion porque con 80 filas de entrenamiento los modelos no lineales sobreajustan. MAE = 6.65 puntos implica un error tipico inferior a 2 victorias en una temporada de 30 partidos.

Tabla 6. Metricas comparativas en test (temporada 2025)

Modelo	MAE	RMSE	R2	Spearman
Ridge	14.7815	17.1671	-0.195	0.5771
Random Forest	12.9719	15.6052	0.0126	0.6273
XGBoost	12.9562	15.4101	0.0371	0.5063

Nota. La temporada 2025 fue atípica por la incorporación de dos clubes recién ascendidos. La correlación de Spearman > 0.5 confirma que el ranking sigue siendo razonable aunque las puntuaciones absolutas se desvían.

3.3 Evidencias de robustez

Las evidencias detalladas de robustez están documentadas en el anexo técnico docs/S9-ANEXOS DE VALIDACION.docx, que incluye:

- **Anexo A.** Partición temporal y distribución de datos.
- **Anexo B.** Pruebas de sensibilidad ante perturbación de predictores.
- **Anexo B.** Validación leave-one-season-out y variabilidad por semilla.
- **Anexo C.** Coeficientes Ridge estandarizados e importancia por permutación.
- **Anexo D.** Mapa de coherencia con el informe principal.

El presente documento se remite a esos anexos para evitar duplicación y mantener la concisión exigida por la rubrica de S10.

4. Pitch del proyecto (5-10 minutos)

Esta seccion contiene el guion estructurado de la presentacion oral del proyecto. Cada bloque incluye el mensaje clave, una estimacion de tiempo y los apoyos visuales sugeridos.

Tabla 7. Estructura y tiempos del pitch

Bloque	Tiempo	Mensaje clave
1. Contexto y problema	1:30 min	Por que predecir puntos en LigaPro vale la pena.
2. Enfoque metodologico	2:00 min	Datos, features y modelos comparados.
3. Resultados y hallazgos	2:30 min	Ridge gana, MAE 6.65, Spearman 0.72.
4. Eticas y robustez	1:30 min	Riesgos, mitigaciones y limitaciones.
5. Cierre y demo de la UI	1:30 min	Mostrar prediccion en vivo en el navegador.

4.1 Contexto y problema abordado

Apertura. La LigaPro Serie A es la maxima categoria del futbol ecuatoriano: 16 clubes, 30 partidos por temporada, presupuestos que varian de 4 a 25 millones de dolares. Esta heterogeneidad presupuestaria convive con una alta incertidumbre deportiva: cada año, en promedio, 5 de los 16 clubes pelean el descenso y otros 5 pelean cupo a Copas internacionales.

Justificacion. Las directivas de los clubes necesitan estimar de manera defendible cuantos puntos pueden lograr ANTES de iniciar la temporada, para fijar objetivos realistas, negociar patrocinios y explicar al directorio el retorno esperado de la inversion en la plantilla. Hoy esa estimacion se hace de forma intuitiva. Nuestro proyecto la convierte en un modelo cuantitativo, reproducible y explicable.

Pregunta de investigacion. ¿Es posible predecir, antes del primer partido, los puntos finales de cada club de la LigaPro a partir de su presupuesto y un conjunto reducido de variables competitivas?

4.2 Enfoque metodologico

Tipos de datos utilizados:

- **Presupuestarios.** Presupuesto anual (MUSD), salario promedio, inversion en refuerzos, valor de plantel y cantidad de fichajes.
- **Plantilla y cuerpo tecnico.** Edad promedio, numero de extranjeros y antigüedad del DT en meses al inicio de temporada.
- **Contexto.** Capacidad del estadio y participacion internacional.
- **Rendimiento rezagado.** Goles a favor / en contra, diferencia, xG y posesion de la temporada anterior (lags).

Modelos aplicados. Se compararon tres modelos de regresion sobre el mismo target (puntos_temporada): (i) Ridge con StandardScaler como linea base interpretable; (ii) Random Forest con 500 arboles; (iii) XGBoost con 400 estimadores.

Principales decisiones tecnicas:

- Particion temporal estricta: train 2019-2023, val 2024, test 2025.
- Imputacion de lags por la mediana SOLO sobre la primera temporada (2019).
- Seleccion automatica del mejor modelo por MAE en validacion.
- Inferencia 100% offline en navegador via exportacion .joblib -> .json.

4.3 Resultados y hallazgos

Metricas finales alcanzadas. El mejor modelo es RIDGE con MAE = 6.6512 puntos y Spearman = 0.7237 en validacion. Esto significa que, en promedio, el modelo se equivoca por menos de 7 puntos (poco mas de dos victorias) y predice correctamente el orden de la tabla con una correlacion fuerte (0.72).

Interpretacion. Ridge gana porque con 80 filas de entrenamiento los modelos no lineales (RF, XGB) sobreajustan: tienen MAE val de 9.3 y 11.4 respectivamente. Esto valida que en datasets pequeños y de señal lineal, la regularizacion L2 es competitiva con metodos mas complejos. Los coeficientes estandarizados de Ridge muestran que el presupuesto y la inversion en refuerzos son los predictores mas fuertes, seguidos por la inercia (puntos / posicion del año previo).

Impacto potencial. Aplicado al inicio de cada temporada, el modelo permite a la directiva: (a) construir un objetivo numerico defendible (rango de puntos esperado +- MAE), (b) comparar el plan deportivo frente a clubes pares con presupuesto similar y (c) cuantificar el impacto marginal de invertir 1 MUSD adicional en refuerzos.

4.4 Consideraciones eticas, riesgos y limitaciones

Principales riesgos identificados:

- **Sesgo de muestra.** Solo 8 temporadas y 16 clubes; los resultados no son extrapolables a otras ligas sin re-entrenamiento.
- **Determinismo aparente.** Mostrar 'el modelo predice 65 puntos' puede leerse como un veredicto. Mitigacion: la UI muestra siempre el MAE como banda de incertidumbre.
- **Riesgo reputacional para clubes.** Una prediccion publica baja podria afectar la moral o la negociacion de patrocinios. Mitigacion: el prototipo se entrega como herramienta interna de planificacion.
- **Cambios normativos.** Modificaciones a los cupos de extranjeros, formato del campeonato o calendario rompen los supuestos. Mitigacion: el reentrenamiento esta automatizado en un solo comando.

Estrategias de mitigacion aplicadas:

- Reporte siempre acompañado de MAE y banda Spearman.
- Particion temporal estricta para evitar leakage del futuro.
- Comparacion frente a baseline lineal interpretable (Ridge).
- Anexos S9 con pruebas de robustez y sensibilidad documentadas.

Limitaciones del modelo:

- Los R2 sobre test 2025 son negativos en Ridge: la temporada fue atípica por dos clubes recién ascendidos. Spearman = 0.58 indica que el ranking sigue siendo razonable.
- El modelo no captura eventos exógenos (lesiones, suspensiones, cambios de DT a mitad de temporada), por diseño: solo opera con información pre-temporada.
- El target son puntos de fase regular, sin considerar play-offs ni desempates.

5. Reflexion final y uso de la retroalimentacion

El proyecto evoluciono desde una idea inicial centrada en predecir directamente la posicion final (variable ordinal con empates) hacia un planteamiento mas solido: predecir puntos_temporada y derivar de alli el ranking via ordenamiento. Este giro, sugerido en la retroalimentacion de S4, fue la decision tecnica de mayor impacto en la calidad del prototipo.

Otras retroalimentaciones incorporadas a lo largo del curso:

- **S2:** organizar los datos por categoria, en vez de un unico CSV monolitico, para facilitar la auditoria de fuentes.
- **S5:** incluir variables rezagadas (lags) de la temporada anterior como proxy de la inercia deportiva.
- **S7:** comparar al menos tres modelos y reportar metricas de ranking (Spearman) ademas de las metricas de regresion clasicas.
- **S8:** priorizar una interfaz limpia y autoexplicativa.
- **S9:** documentar formalmente la robustez del modelo en un anexo independiente y trazable.
- **S10:** eliminar la dependencia del backend para que el evaluador pueda probar el prototipo abriendo un solo archivo HTML.

Aprendizajes clave del equipo. (i) En datasets pequeños la regularizacion lineal es dificil de batir; resistir la tentacion de escalar a modelos complejos sin justificarlo. (ii) La trazabilidad (model_card.json) es tan importante como las metricas mismas: permite que cualquier evaluador reconstruya las decisiones. (iii) La separacion en capas (datos / modelo / inferencia) reduce drasticamente el costo de incorporar retroalimentaciones tardias.

Trabajo futuro. Ampliar el horizonte de datos a 12 - 15 temporadas, integrar series economicas exogenas (PIB, dolarizacion del salario minimo), modelar partido a partido con efectos aleatorios por equipo y publicar la API en un servicio gestionado para uso de directivas y analistas deportivos.