



FACULTAD DE INGENIERÍA Y CIENCIAS APLICADAS

MAESTRÍA EN INTELIGENCIA ARTIFICIAL APLICADA

PROYECTO MIA

PROPUESTA DEL PROYECTO DE TITULACIÓN

Modelo predictivo del rendimiento deportivo en el fútbol ecuatoriano a partir del presupuesto institucional y variables competitivas usando técnicas de Inteligencia Artificial

TUTOR: Medina Sotomayor Jaime Felipe.

AUTOR1: Castro García Diego Fernando

AUTOR2: Pila Caiza Cesar Silvio

Índice

Índice	2
Resumen	4
1. Introducción	5
1.1 Contextualización del problema organizacional	5
1.2 Justificación del proyecto y su relevancia	5
1.3 Objetivos	5
Objetivo general.....	5
Objetivos específicos.....	6
2. Marco teórico y estado del arte.....	7
2.1 Síntesis de los principales aportes de la literatura revisada	7
2.2 Tendencias, enfoques metodológicos y vacíos identificados	7
2.3 Relación con el problema abordado	7
3. Metodología.....	9
3.1 Descripción del diseño metodológico	9
3.2 Fuentes y preparación de los datos	9
3.3 Técnicas y modelos de IA utilizados	10
3.4 Métricas de evaluación	10
3.5 Consideraciones éticas y de sesgo	11
4. Resultados preliminares.....	11
4.1 Descripción del prototipo desarrollado	11
4.2 Resultados obtenidos	11
4.3 Análisis del desempeño del modelo	12
5. Validación e interpretabilidad	13

5.1 Técnicas de validación aplicadas	13
5.2 Análisis de interpretabilidad (XAI).....	13
5.3 Pruebas de robustez realizadas	14
5.4 Riesgos identificados y estrategias de mitigación	14
6. Conclusiones preliminares y trabajo futuro.....	15
6.1 Principales aprendizajes	15
6.2 Aportes del proyecto	15
6.3 Líneas de mejora	15
7. Referencias	16

Resumen

El proyecto desarrolla un modelo predictivo del rendimiento deportivo de los clubes de la LigaPro Serie A de Ecuador, utilizando como insumos principales variables financieras e institucionales (presupuesto anual, inversión en refuerzos, valor de plantel, edad promedio, participación internacional y posición de la temporada anterior). Se construyó un pipeline reproducible en Python que ingiere los datos reales del periodo 2019-2026 provistos por la dirección financiera de los clubes, los normaliza, consolida los dieciséis equipos por temporada y ajusta tres familias de algoritmos: Regresión Ridge, Random Forest y Gradient Boosting. Los resultados preliminares con datos reales muestran que el modelo Ridge alcanza un MAE de 6.52 puntos y una correlación de Spearman de 0.75 en la temporada de validación (2024), superando claramente los resultados preliminares obtenidos con datos ficticios en fases anteriores. El documento integra también el análisis de interpretabilidad inicial (coeficientes y permutación importance), las consideraciones éticas y los pasos pendientes para la versión final.

1. Introducción

1.1 Contextualización del problema organizacional

La LigaPro Serie A es la primera categoría del fútbol profesional ecuatoriano y agrupa a dieciséis clubes cuyos presupuestos operativos oscilan, según la base consolidada del proyecto, entre 0.7 y 20.3 millones de dólares al año. A pesar de que la dirigencia de cada club ejecuta ciclos anuales de planificación financiera y deportiva, la decisión de cuanto invertir en refuerzos, cuerpo técnico y plantel se realiza tradicionalmente con escaso soporte cuantitativo: se privilegian la intuición, la presión mediática y comparaciones puntuales con equipos vecinos. Esta práctica genera alta variabilidad interanual, un nivel de riesgo financiero elevado y, con frecuencia, resultados deportivos que no reflejan la inversión realizada. El problema organizacional concreto es la inexistencia de una herramienta técnica que traduzca las variables económicas e institucionales disponibles antes de iniciar la temporada en una expectativa realista de desempeño deportivo, expresada como puntos al cierre del torneo o como posición final estimada.

1.2 Justificación del proyecto y su relevancia

El proyecto se justifica en tres planos. En lo académico, permite aplicar técnicas de aprendizaje automático supervisado e interpretabilidad explicable, a un dominio escasamente explorado en la literatura regional: el fútbol sudamericano de mercado emergente. En lo institucional, brinda a los clubes y a la propia Liga una referencia objetiva para dialogar con patrocinadores y auditores, y para priorizar partidas presupuestarias con evidencia empírica. En lo social, contribuye a profesionalizar la gestión deportiva en un país donde el fútbol moviliza recursos económicos y mediáticos significativos, promoviendo transparencia en la toma de decisiones.

1.3 Objetivos

Objetivo general

Desarrollar un modelo de inteligencia artificial que estime el desempeño deportivo anual (puntos y posición final) de los clubes de la LigaPro Serie A a partir de variables financieras e institucionales disponibles antes del inicio de la temporada.

Objetivos específicos

- Consolidar una base de datos histórica de los clubes de la LigaPro para el periodo 2019-2026 integrando información financiera, de plantel y de participación internacional.
- Diseñar un pipeline reproducible de preprocesamiento, entrenamiento y validación comparativa para tres familias de modelos (Ridge, Random Forest y Gradient Boosting).
- Aplicar técnicas de interpretabilidad (coeficientes, permutación importance y feature importance) que permitan explicar las predicciones a la dirigencia.
- Identificar riesgos éticos y de sesgo asociados al uso del modelo e incluir recomendaciones de mitigación.

2. Marco teórico y estado del arte

2.1 Síntesis de los principales aportes de la literatura revisada

La economía del deporte establece, desde los trabajos seminales de Szymanski (2003) y Kuper y Szymanski (2009), que el gasto en salarios es el mejor predictor individual del éxito deportivo en las ligas europeas, explicando entre el 70 % y el 90 % de la variabilidad de la clasificación final. En ligas latinoamericanas la correlación sigue siendo positiva pero más débil, y se ve moderada por factores como la participación en torneos internacionales, la edad y composición del plantel y la estabilidad del cuerpo técnico. En el plano metodológico, Breiman (2001) introduce Random Forest como un estimador robusto a la correlación entre predictores y el ruido típico de datos deportivos; Chen y Guestrin (2016) consolidan XGBoost como estándar para tareas tabulares por su regularización integrada. La escuela de interpretabilidad representada por Lundberg y Lee (2017) con los valores SHAP y por Ribeiro, Singh y Guestrin (2016) con LIME justifica el uso de métodos XAI para traducir las predicciones en explicaciones accionables. Pedregosa et al. (2011) documentan las implementaciones de referencia en scikit-learn utilizadas en este proyecto.

2.2 Tendencias, enfoques metodológicos y vacíos identificados

La literatura reciente en analítica deportiva privilegia (i) el uso de variables pretemporada como predictores de resultado anual, (ii) la combinación de regresión lineal regularizada como línea base con modelos no lineales basados en árboles, y (iii) la adopción de validación temporal en lugar de validación cruzada aleatoria, para respetar el carácter secuencial del calendario. En Ecuador no se identifican trabajos publicados que apliquen este esquema a la totalidad de los clubes de la máxima división; los estudios existentes se concentran en equipos específicos y en temporadas puntuales, sin un pipeline reproducible ni una capa de interpretabilidad formal. Los vacíos principales son entonces la ausencia de un dataset abierto y consolidado por club y temporada, la falta de comparación sistemática entre algoritmos y la baja incorporación de interpretabilidad en reportes dirigidos a dirigentes.

2.3 Relación con el problema abordado

El problema organizacional descrito en la Introducción se enmarca exactamente en ese vacío: necesitamos un modelo reproducible, validado en condiciones temporales reales y acompañado de explicaciones comprensibles. El marco teórico proporciona los algoritmos (Ridge, Random Forest, Gradient Boosting), las variables relevantes (gasto en salarios, refuerzos, participación internacional, antigüedad del DT) y los criterios de evaluación (MAE, R2, Spearman) que guían la metodología del siguiente apartado.

3. Metodología

3.1 Descripción del diseño metodológico

El diseño es cuantitativo, de tipo predictivo supervisado, con estructura longitudinal por club y temporada. Cada fila del dataset consolidado representa la combinación equipo-temporada y combina variables conocidas antes del inicio del campeonato (predictores) con el resultado observado al final de la temporada (variable objetivo). La variable objetivo principal es puntos temporada y la variable secundaria es posición final (1-16). Se adopta validación temporal estricta: las temporadas 2019-2023 se utilizan para entrenamiento, 2024 para validación y 2025 para prueba; la temporada 2026 se reserva como referencia y para generar pronósticos prospectivos.

3.2 Fuentes y preparación de los datos

La fuente principal es el archivo DATOS FINANZAS - LIGAPRO 2019-2026.xlsx, elaborado por el equipo de trabajo a partir de información publicada por los propios clubes, por la Federación Ecuatoriana de Fútbol y por Transfermarkt. El archivo contiene ocho hojas (una por temporada) con las columnas: equipo, presupuesto, gasto en fichajes, cantidad de fichajes, tendencia presupuestaria, valor de plantel, promedio de edad, puntos de la temporada anterior, puesto de la temporada actual, eficiencia de temporada, ingresos Conmebol y estimado de sueldos. El proceso de preparación se implementó en el script `scripts/cargar_datos_reales.py` e incluye: (i) normalización de nombres de clubes, removiendo tildes y estandarizando mayúsculas; (ii) limpieza de valores monetarios, eliminando los sufijos "usd" y convirtiendo formatos ibéricos (1.234,56) a números flotantes; (iii) conversión de porcentajes y de la columna puesto (por ejemplo "6o") a valores enteros; (iv) construcción de puntos reales por club y temporada mediante el lookup cruzado con la columna "puntos anterior" de la hoja siguiente; y (v) generación de ocho CSV por categoría (equipos, presupuestos, plantilla, cuerpo técnico, participación internacional, rendimiento ofensivo, rendimiento defensivo y posiciones), compatibles con el pipeline original del repositorio. Finalmente, el script `scripts/consolidar_dataset.py` une los CSV por equipo-temporada, crea la variable rezagada (estadísticas de la temporada anterior) y produce `dataset_final.csv` junto con los splits `train.csv`, `val.csv` y `test.csv`.

La base final contiene 128 filas útiles (equipo x temporada), con 30 clubes distintos a lo largo de ocho temporadas. Cuando se reemplazaron los datos ficticios iniciales por los reales dejó de ser necesario ejecutar el script `generar_datos_ficticios.py`; no obstante, se conserva en el repositorio como utilidad de respaldo para pruebas unitarias y regresión del pipeline.

3.3 Técnicas y modelos de IA utilizados

Se comparan tres familias de algoritmos representativas del espectro "interpretable vs. flexible":

1. Regresión Ridge (lineal regularizada, $\alpha = 1.0$, con `StandardScaler`). Sirve como línea base interpretable: los coeficientes estandarizados permiten explicar en unidades comparables la sensibilidad del puntaje estimado a cada predictor.
2. Random Forest (500 árboles, `min_samples_leaf = 2`, `random_state = 42`). Captura interacciones no lineales y es robusto al ruido y a escalas distintas entre variables.
3. Gradient Boosting (`scikit-learn`, 400 estimadores, `learning_rate = 0.05`, profundidad 3). Se utiliza como fallback de XGBoost cuando la dependencia no está disponible; ofrece el mejor compromiso teórico entre sesgo y varianza en datasets tabulares pequeños.

Los tres modelos se ajustan sobre el mismo conjunto de catorce predictores: presupuesto, salario promedio, inversión en refuerzos, edad promedio, número de extranjeros, antigüedad del DT, participación internacional, capacidad del estadio, posición del año anterior y cinco variables rezagadas de rendimiento deportivo (goles a favor, goles en contra, diferencia de goles, `expected goals` y porcentaje de posesión de la temporada previa). Se eligen estos predictores porque son todos conocidos antes del primer partido de la temporada y, por tanto, se pueden utilizar en producción para apoyar decisiones presupuestarias.

3.4 Métricas de evaluación

Para comparar los modelos se reportan cuatro métricas complementarias: MAE (Mean Absolute Error) en la escala natural del negocio, es decir en puntos del torneo; RMSE, que penaliza errores grandes; coeficiente de determinación R^2 , que expresa la varianza explicada; y correlación de Spearman entre puntos observados y predichos, útil para

medir la calidad del ordenamiento (posición final). Se considera mejor modelo el que minimice el MAE en la temporada de validación (2024).

3.5 Consideraciones éticas y de sesgo

Se identifican tres ámbitos sensibles. Primero, el riesgo de amplificar la desigualdad histórica de la liga: un modelo alimentado por presupuesto puede reforzar la idea de que los clubes con menos recursos están predestinados a la parte baja de la tabla. Este efecto se mitiga incluyendo variables de contexto (edad del plantel, antigüedad del DT, participación internacional) y publicando siempre intervalos de incertidumbre, no pronósticos puntuales. Segundo, la privacidad de los datos salariales: el archivo fuente contiene solo agregados estimados a partir de información pública, por lo que no se procesan datos personales identificables de jugadores. Tercero, la apropiación política del modelo: se recomienda que el informe final incluya cláusulas explícitas de uso responsable y advertencias sobre los límites de la inferencia causal, para evitar que la herramienta sea utilizada para justificar decisiones que, en la práctica, dependen de la gestión deportiva.

4. Resultados preliminares

4.1 Descripción del prototipo desarrollado

El prototipo es una aplicación de scripts Python organizada en cinco capas: (1) scripts/cargar_datos_reales.py para ingesta desde Excel; (2) scripts/consolidar_dataset.py que une y rezaga las variables; (3) scripts/preprocesamiento.py que define features, target y partición temporal; (4) scripts/entrenamiento.py que ajusta, valida y serializa los tres modelos en formato joblib; y (5) scripts/prediccion.py que aplica el mejor modelo a temporadas futuras. El notebook notebooks/01_ligapro_edu_y_modelado.ipynb centraliza el análisis exploratorio y la comparación visual. El mejor modelo (Ridge) se persiste como models/mejor_modelo.joblib y sus métricas se registran en models/model_card.json. Los predictores y predicciones se exportan a reports/val_predictions_powerbi.csv y reports/test_predictions_powerbi.csv para su consumo desde Power BI.

4.2 Resultados obtenidos

Sobre el dataset real consolidado (128 filas), con partición temporal 2019-2023 / 2024 / 2025, los resultados en validación son:

Modelo	MAE (val 2024)	RMSE (val 2024)	R2 (val 2024)	Spearman (val)
Ridge (mejor modelo)	6.52	7.81	0.63	0.75
Random Forest	9.32	10.92	0.27	0.46
Gradient Boosting (fallback de XGBoost)	9.38	10.75	0.30	0.35

El modelo Ridge es el mejor desempeño en validación, con un MAE de 6.5 puntos (aproximadamente 7 % de los 90 puntos maximos disponibles) y un Spearman de 0.75 que indica una buena reproducción del ordenamiento de los clubes. Los modelos no lineales (Random Forest y Gradient Boosting) se comportan peor en este escenario, lo que es coherente con el tamaño pequeño del dataset (128 filas con 14 predictores): con tan pocos casos, el sesgo inductivo lineal del Ridge generaliza mejor que el mayor poder expresivo de los árboles. Sobre la partición de prueba (2025) el Ridge mantiene un Spearman de 0.68, aunque con un MAE más alto (14.7 puntos) porque los presupuestos de 2025 muestran una inflación relativa respecto a los anos de entrenamiento.

4.3 Análisis del desempeño del modelo

El análisis cualitativo de las predicciones de validación confirma la dirección correcta: Liga Deportiva Universitaria (65 puntos reales) y Barcelona SC (56) son predichos como los equipos con mayor puntaje, mientras que los recién ascendidos (Imbabura, Cumbayá) ocupan la parte baja. Los principales errores se concentran en dos casos: (i) Emelec en 2024 (34 puntos reales frente a 50 predichos), porque su presupuesto histórico no anticipa la crisis deportiva vivida esa temporada; y (ii) Mushuc Runa y Universidad Catolica, con desempeños por encima de lo que su presupuesto sugiere, evidenciando el efecto de una gestión deportiva eficiente que el modelo actual no captura.

5. Validación e interpretabilidad

5.1 Técnicas de validación aplicadas

La validación utiliza tres mecanismos complementarios. Primero, partición temporal estricta (entrenamiento 2019-2023, validación 2024, prueba 2025) que respeta la lógica cronológica del negocio y evita fugas de información hacia el futuro. Segundo, reporte de cuatro métricas con distinta sensibilidad: MAE, RMSE, R2 y correlación de Spearman; la última es particularmente relevante porque mide la calidad del ordenamiento, que es al final lo que importa para la tabla de posiciones. Tercero, un baseline ingenuo consistente en predecir la mediana histórica de puntos (42 puntos), que obtuvo un MAE de 12.1 en validación; todos los modelos entrenados superan holgadamente ese baseline.

5.2 Análisis de interpretabilidad (XAI)

Para el mejor modelo (Ridge) se reporta a continuación el ordenamiento de coeficientes estandarizados, que se interpretan directamente como impacto marginal en puntos del torneo cuando la variable aumenta una desviación estándar:

Variable	Coeficiente Ridge	Interpretación
Posición _temporada _ anterior	-3.99	Cada puesto mejor el año anterior anticipa ~4 puntos más.
Inversión _ refuerzos	+3.74	Cada millón adicional en fichajes incrementa ~3.7 puntos.
Participación _ internacional	+2.92	Disputar Libertadores o Sudamericana suma ~3 puntos.
Salario _ promedio	+1.60	Mayor salario medio se asocia con mejor desempeño.
presupuesto	+1.60	Efecto directo del presupuesto total (colinealidad con salarios).
Goles_ contra _ ant	+1.17	Efecto residual tras controlar por otros factores; requiere análisis.

Edad _ promedio _ plantilla	-1.12	Planteles muy mayores tienden a rendir un poco menos.
--------------------------------	-------	---

Las tres variables dominantes son consistentes con la literatura: la posición del año anterior (efecto inercia, el club que termino bien tiende a repetir), la inversión en refuerzos (que actúa como proxy de agresividad financiera) y la participación internacional (que aporta rodaje y atractivo para contrataciones). Para la versión final se complementará con análisis por permutación y valores SHAP calculados sobre un Random Forest reentrenado con datos aumentados, para contrastar la linealidad asumida por Ridge.

5.3 Pruebas de robustez realizadas

- Perturbación de predictores: se añadió ruido gaussiano del 5 % al presupuesto; el MAE en validación subió de 6.52 a 6.84, variación aceptable (<5 %).
- Eliminación de una temporada: al excluir 2023 del entrenamiento, el MAE en validación aumenta a 7.30, confirmando que ninguna temporada concentra el aprendizaje del modelo.
- Cambio de semilla: con diez semillas distintas, los modelos basados en arboles muestran desviación estándar de 0.4 en MAE, mientras que Ridge es invariante.

5.4 Riesgos identificados y estrategias de mitigación

Los principales riesgos del modelo son cuatro. (a) Inflación presupuestaria no estacionaria: los valores nominales en dólares de 2025 no son comparables con los de 2019 sin ajuste; para la versión final se deflactarán los montos usando el IPC ecuatoriano como covariable de control. (b) Sesgo de selección por ascensos y descensos: los clubes recién ascendidos tienen una sola observación y su estimación es volátil; se trabajará con regularización bayesiana (Bayesian Ridge) y con variables de "tiempo en primera" para modelar la experiencia. (c) Variables deportivas rezagadas aproximadas: goles a favor, goles en contra y xG se estimaron a partir de la eficiencia de temporada por falta del dato real; en la versión final se incorporará la fuente de Opta/Transfermarkt para tenerlos medidos. (d) Riesgo ético de refuerzo de desigualdad: se comprometerá al final del informe una sección explícita de "uso responsable", recomendando que el modelo se presente como apoyo a la decisión y no como pronóstico determinista.

6. Conclusiones preliminares y trabajo futuro

6.1 Principales aprendizajes

El avance permite confirmar tres hallazgos. Primero, que las variables financieras e institucionales, por si solas, explican una fracción sustantiva del rendimiento anual de los clubes de la LigaPro: el modelo Ridge alcanza un R^2 de 0.63 en validación con solo catorce predictoras pretemporadas. Segundo, que el esquema de validación temporal es imprescindible: pruebas preliminares realizadas con validación cruzada aleatoria sobreestimaban el desempeño en más de diez puntos de MAE. Tercero, que la interpretabilidad es viable desde el primer iterado; los coeficientes estandarizados ya ofrecen una narrativa útil para conversar con dirigentes.

6.2 Aportes del proyecto

- Un pipeline reproducible (cinco scripts, un notebook) que puede reentrenarse en segundos en cualquier laptop moderna.
- Un dataset consolidado y documentado de la LigaPro 2019-2026, inédito en la literatura abierta del fútbol ecuatoriano.
- Un informe técnico preliminar con métricas, interpretabilidad y análisis de riesgos.

6.3 Líneas de mejora

1. Incorporar datos deportivos medidos (goles a favor, goles en contra, xG, posesión, minutos jugados por extranjeros) desde Opta o Transfermarkt, reemplazando las aproximaciones actuales basadas en eficiencia.
2. Deflactar los montos monetarios con IPC de Ecuador para comparar temporadas en términos reales.
3. Agregar análisis SHAP a los modelos de árboles, construir dashboards interactivos en Power BI y preparar un documento técnico-ejecutivo para la dirigencia de la LigaPro.
4. Ampliar la hipótesis al modo clasificación (campeón, clasifica a Copa Libertadores, descenso) y reportar calibración con métricas como log loss y Brier score.
5. Redactar la sección de uso responsable, revisión ética y gobernanza de datos en la versión final del informe.

7. Referencias

- Breiman, L. (2001). Random forests. Machine Learning, 45(1), 5-32. <https://doi.org/10.1023/A:1010933404324>
- Chen, T., y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (pp. 785-794). ACM. <https://doi.org/10.1145/2939672.2939785>
- Federacion Ecuatoriana de Futbol. (2024). Reglamento de la LigaPro Serie A 2024. LigaPro Ecuador.
- Kuper, S., y Szymanski, S. (2009). Soccernomics: Why England loses, why Spain, Germany, and Brazil win, and why the U.S., Japan, Australia, Turkey and even Iraq are destined to become the kings of the world's most popular sport. Nation Books.
- Lundberg, S. M., y Lee, S.-I. (2017). A unified approach to interpreting model predictions. Advances in Neural Information Processing Systems, 30, 4765-4774.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825-2830.
- Ribeiro, M. T., Singh, S., y Guestrin, C. (2016). "Why should I trust you?": Explaining the predictions of any classifier. En Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (pp. 1135-1144). <https://doi.org/10.1145/2939672.2939778>
- Szymanski, S. (2003). The economic design of sporting contests. Journal of Economic Literature, 41(4), 1137-1187. <https://doi.org/10.1257/002205103771800004>
- Transfermarkt. (2024). LigaPro Serie A — Valor de mercado y plantillas [Conjunto de datos]. Transfermarkt GmbH. <https://www.transfermarkt.com>

Documentación del repositorio

https://drive.google.com/drive/folders/1HLFuxHa46t1-P-L9tQXx1_AISOvYcwyA?usp=sharing

Dentro de la carpeta **LigaPRO Serie A** se encuentra el notebook principal que se llama **01_ligapro_COLAB.ipynb**

LigaPRO Serie A

```
|— notebooks/  
  |— 01_ligapro_COLAB.ipynb
```